1. Giriş

Bu proje, başlangıçta klasik veri analizi ve işleme yöntemlerine dayanarak yapılandırılmış veriler üzerinde anlamlı sonuçlar elde etmeyi amaçlayan bir proje olarak başladı. İlk adımda, sanal bir veri seti oluşturuldu ve bu veri üzerinde çeşitli veri temizleme ve ayıklama işlemleri gerçekleştirildi. Ardından, bu yapılandırılmış verileri embedding modelleri kullanılarak tüm CSV dosyası vektörleştirildi ve FAISS üzerinde depolandı. Bu süreçte, kullanıcının doğal dilde sorularına anlamlı cevaplar üretebilmek için OpenAI'nin GPT-3.5-turbo modeli entegre edildi. GPT-3.5-turbo modelinin kullanılmasının en büyük sebebi prototipin sizler tarafından gerçek zamanlı kullanımda daha hızlı yanıt vermesi içindir. Gerekli sunucu tedariği sonucunda Llama-3, Llama-3.1 gibi açık kaynaklı modellerin entegresi kolayca sağlanabilir.

Ancak, yapılandırılmış verilerden elde edilen sonuçlar, yapılandırılmamış verilerdeki gibi tatmin edici olmadı. Bu yöntem, beklenenin aksine, CSV gibi yapılandırılmış veriler üzerinde etkili sonuçlar vermedi. Yapılandırılmış verilerin zaten bir anlam taşıyan kategorik yapısı, vektörleştirildiğinde kayboluyor ve sonuçların doğruluğu önemli ölçüde düşüyordu. Bu hayal kırıklığı, projenin yönünü değiştirdi ve yeni bir çözüm arayışına yöneltti.

Araştırmalarım, yapılandırılmış verilerde yüksek başarı elde etmenin anahtarının, sorgu tabanlı bir yaklaşıma dayanması gerektiğini gösterdi. LLM (Large Language Model) teknolojilerinin sorgu üzerinden daha etkili çözümler sunabileceğini fark ettim. Bu yeni yaklaşımda, vektörleştirme işlemi yalnızca kullanıcının sorgusuna göre en alakalı sütunları belirlemek için kullanıldı. Örneğin, veri setinde "Konum", "HTTP Yöntemi" ve "Durum Kodu" gibi sütunlar bulunuyorsa ve kullanıcı "Kaç farklı mesken vardır?" şeklinde bir soru soruyorsa, RAG (Retrieval-Augmented Generation) teknolojisi konum ve mesken arasında anlamlı bir bağ kurdu. Sistem, sorguyu konum sütununa yönlendirdi ve OpenAI GPT-3.5-turbo modelinin desteğiyle doğru yanıtı üretebildi.

Bu yeni yaklaşım, yapılandırılmış verilerle çalışırken performans ve doğruluk açısından çok daha başarılı sonuçlar sağladı. Bu proje, geleneksel veri analizi ve vektörleştirme yöntemlerinin ötesine geçerek, LLM tabanlı sorgu teknolojisinin nasıl entegre edilebileceğini göstermektedir.

Aşağıda bulunan linkteki kullanacağınız veri setinin ismi "data.csv". Lütfen bu sistemi kullanırken tırnak içerisinde belirtilen veriyi sisteme yükleyip sorgularınızı çalıştırınız.

Projenin Gerçek Zamanlı Test Linki: https://cs8q9jzbzelbehrgbvuucu.streamlit.app (eğer sisteme girdiğinizde çökmüş olursa lütfen bana ulaşın. Çünkü streamlitin 1GB Free hakkı var ve model çalışıp çıktı ürettikçe hafıza doluyor ve "out of memory" gibi hatalar ile projeyi çökertiyor. Sistemi ReBoot yapınca free memory hakkımız yenileniyor ve verileri tekrardan yükleyip çalıştırabiliyoruz.)

Projenin Test Video Linki (Saf Sorgu): https://youtu.be/EWyw0yaa3EA

Projenin Test Video Linki (Veri Görselleştirme): https://youtu.be/If0q3UztiHY

2. Proje Adımları

2.1. Gereksinimlerin Belirlenmesi ve Ortamın Hazırlanması

Projenin başlangıcında, semantik arama işlevselliği sağlamak için uygun teknolojilerin belirlenmesi kritik bir adımdı. Bu süreçte FAISS, SentenceTransformers, OpenAI'nin GPT modelleri ve Llama Index gibi teknolojilerin uygun olduğuna karar verildi. Ayrıca, kullanıcı arayüzü için Streamlit platformunun kullanılması kararlaştırıldı.

2.2. CSV Dosyasının Yüklenmesi ve İlk İşlemeler

İlk olarak, kullanıcının yüklediği CSV dosyasının uygun bir şekilde işlenmesi sağlandı. Yüklenen veriler bir pandas DataFrame olarak okunup, kullanıcının görüntülemesine olanak tanındı. Bu aşama, veri üzerinde yapılacak işlemler için temel teşkil etti.

2.3. Semantik Arama İçin FAISS ve SentenceTransformers Kullanımı

Uygulamanın ana işlevselliği, CSV dosyasındaki sütun adlarının semantik olarak vektörleştirilmesi ve FAISS kullanılarak bu vektörlerin saklanması üzerine kuruldu. Kullanıcının sorgusu da aynı yöntemle vektörleştirilerek, FAISS ile en alakalı sütunlar belirlendi. Bu adım, kullanıcının doğal dilde yazdığı sorgularla, verideki en uygun sütunlar üzerinden arama yapabilmesini sağladı.

2.3.1. En İyi Embedding Modelinin Seçimi

Bu projede kullanılan embedding modeli, sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 modelidir. Bu model, Türkçe de dahil olmak üzere birçok dilde etkili performans göstermesiyle bilinir. Diğer birçok embedding modeli, özellikle Türkçe gibi dil bilgisel yapısı karmaşık dillerde zayıf sonuçlar verebilir. Örneğin, bert-base-multilingual-cased gibi diğer modeller, Türkçe'deki ince ayrımları ve anlam ilişkilerini yeterince yakalayamadığından, semantik arama ve RAG (Retrieval-Augmented Generation) gibi uygulamalarda performans sorunları yaşayabilir. Bu nedenle, Türkçe dilinde yüksek doğruluk sağlayan ve düşük gecikme sunan paraphrase-multilingual-MiniLM-L12-v2 modelinin seçilmesi, projenin başarısı açısından kritik bir rol oynadı.

2.4. LLM Entegrasyonu ile Pandas Sorgusu

En alakalı sütunlar belirlendikten sonra, LLM desteği ile bu sütunlar üzerinden bir Pandas sorgusu oluşturuldu. Bu sorgu, kullanıcının isteğine uygun olarak dinamik bir şekilde oluşturuldu ve sonuçlar kullanıcıya sunuldu. Bu adımda OpenAI'nin GPT-3.5-turbo modeli kullanıldı.

2.5. QueryPipeline ile Sorgu Akışının Yönetimi

Sorgu akışının daha sistematik bir şekilde işlenmesi amacıyla Llama Index'in QueryPipeline yapısı kullanıldı. Bu yapı, kullanıcının sorgusunu işleyerek uygun bir şekilde sonuç üreten adımları yönetti ve sonucun kullanıcıya sunulmasını sağladı.

3. Karşılaşılan Zorluklar

3.1. Vektör Veritabanları ve Yapılandırılmış Veriler

Projenin başında, CSV dosyasındaki verilerin tamamını vektörleştirerek bunları FAISS ile saklayıp, kullanıcı sorgusuna uygun sonuçları getirme yöntemi denendi. Ancak bu yaklaşımın bazı ciddi kısıtlamaları olduğu fark edildi:

3.1.1. Vektör Veritabanları Neden Yapılandırılmış Veriler İçin Harika Değil?

Vektör veritabanları, yapılandırılmamış verilerde harika sonuçlar üretirler. Örneğin, metin, görsel veya ses gibi veri türlerinde, bu verileri vektör uzayına taşıyarak semantik yakınlıklarını hesaplamak mümkündür. Ancak yapılandırılmış veriler (örneğin, bir CSV dosyasındaki sütunlar) zaten anlamlı bir yapı taşır ve bu yapıyı korumak önemlidir.

Yapılandırılmış verilerde, her sütun genellikle belirli bir özellik veya kategoriye karşılık gelir ve bu sütunların birbirleriyle olan ilişkileri belirgindir. Bu nedenle, bu verileri vektörleştirip FAISS gibi bir vektör veritabanına koymak, bu anlamlı yapıyı kaybetmeye yol açabilir. Ayrıca, bu veritabanları genellikle belirli bir sorguya göre en yakın vektörleri getirmek üzerine tasarlanmıştır; ancak bir CSV dosyasındaki tüm sütunlar semantik olarak anlamlı olmayabilir. Bu da veritabanından alınan sonuçların tutarlılığını ve doğruluğunu etkileyebilir.

3.1.2. Performans ve Sonuçlar

RAG teknolojisi, bu kısıtlamaların üstesinden gelmek için kullanıldı. Kullanıcı sorgusuna göre en alakalı sütunları belirleyip, yalnızca bu sütunlar üzerinden bir sorgu yapılması daha etkili bir yaklaşım olarak belirlendi. Örneğin, bir CSV dosyasında "Konum", "HTTP Yöntemi" ve "Durum Kodu" gibi sütunlar bulunduğunu düşünelim. Eğer kullanıcı "Kaç farklı mesken vardır?" diye bir soru sorarsa, RAG teknolojisi, "mesken" ve "konum" arasında anlamlı bir ilişki kurar. Bu ilişki kurulduktan sonra, sistem Konum sütunundan sorgu yaparak, OpenAI GPT-3.5-turbo modelinin yardımıyla bu sorguya uygun bir yanıt üretir.

4. Türkçe için Embedding Modellerinin Karşılaştırılması

4.1. sentence-transformers/distiluse-base-multilingual-cased-v1

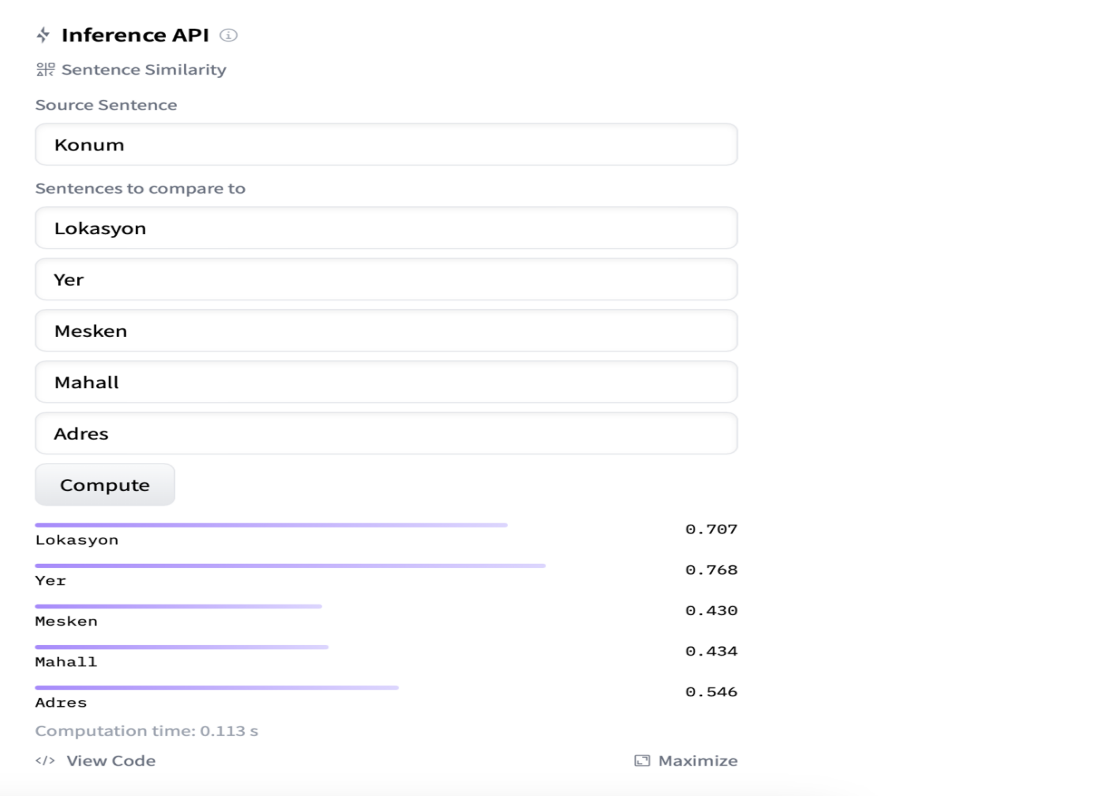

4.2. sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2

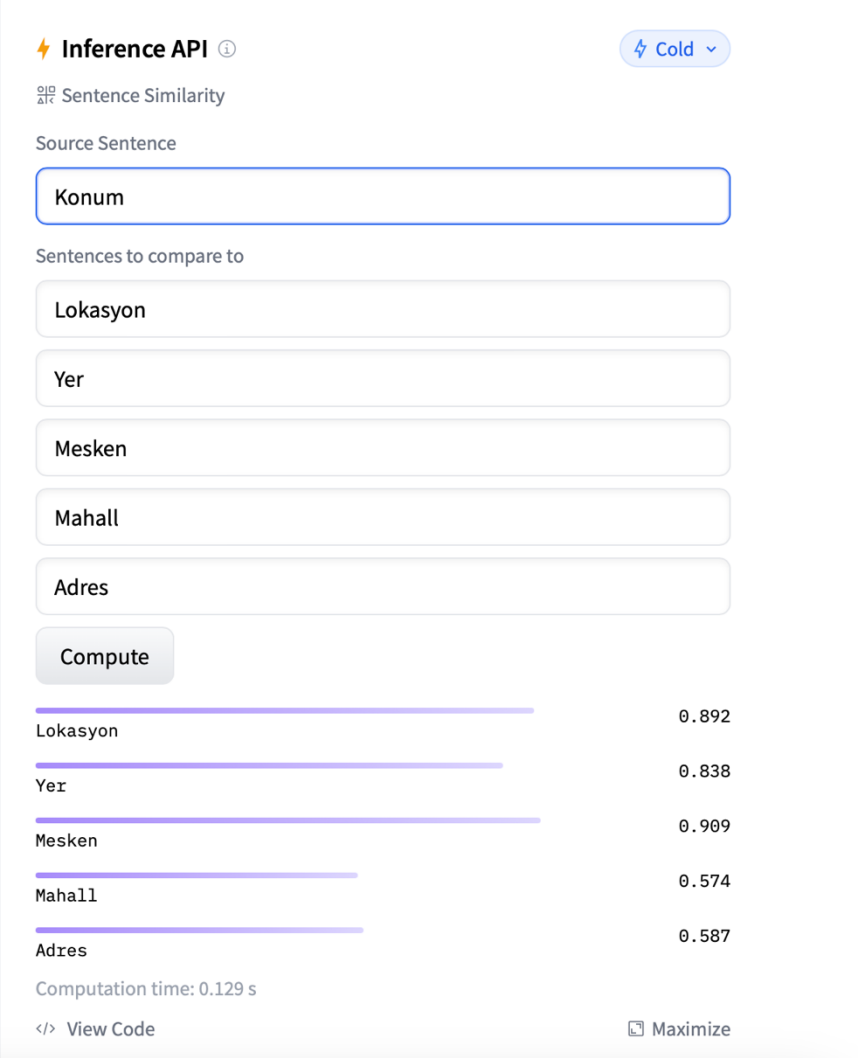

4.3. sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2

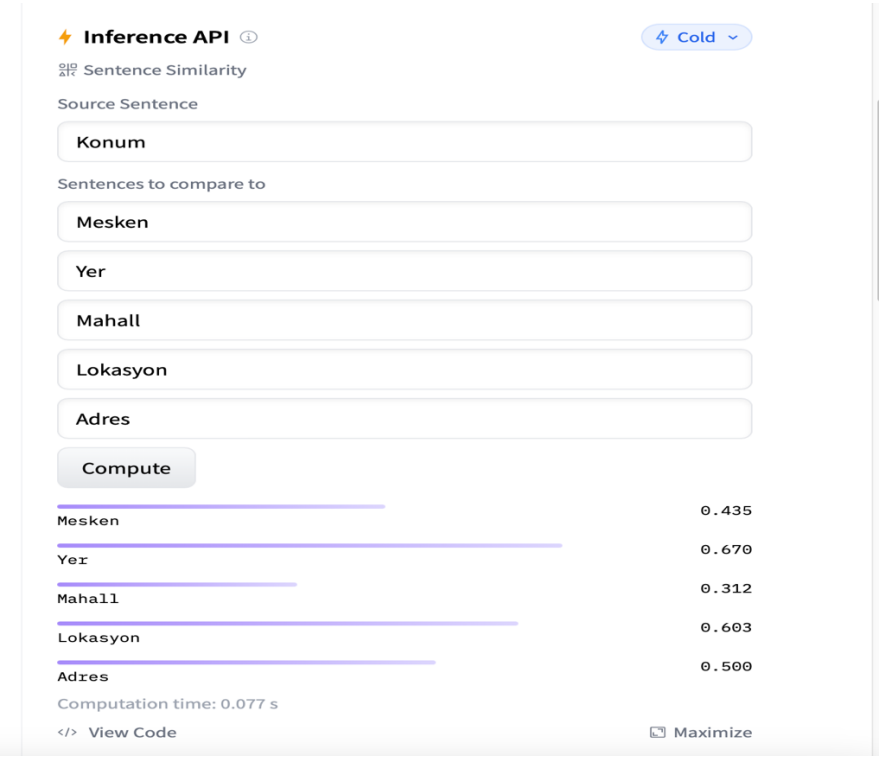

Embedding Modellerinin çıktıları incelendiğinde en başarılı performans gösteren embedding modeli **sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2**. İkinci performansı en yüksek model **sentence-transformers/distiluse-base-multilingual-cased-v1** ve son olarak en kötü performansa sahip **sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2** modelidir. Sonuç çıktıları incelendiğinde ilgili projede kullanılacak embedding modeli **sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2** olarak belirlenmiştir.

5. Oluşturulan Sistemin Kullanım Kılavuzu

5.1 Veri Yükleme

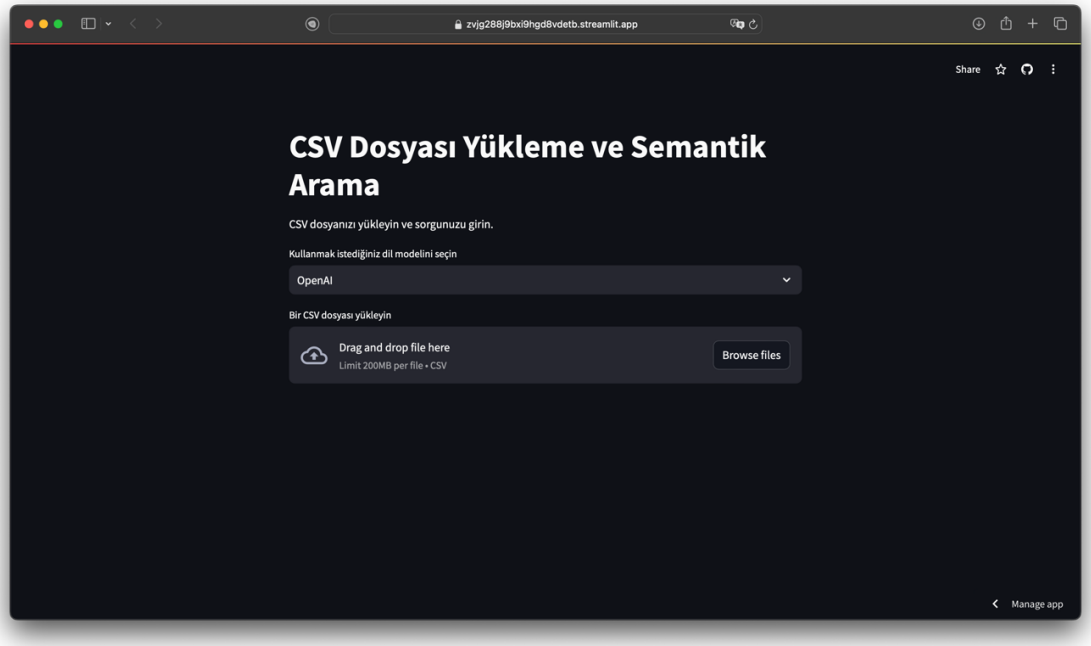

Şekil 1.

Şekil 1.'de görülen sistemin arayüzüdür. Bu arayüzde model seçimi yapılan kısımdan istediğiniz modeli seçmenize olanak tanınmaktadır. Şu anda kısıtlı bellek açısından sadece OpenAI-3.5-Turbo modelinin API entegrasyonu bulunmaktadır. İlgili sunucu tedariği sonucu açık kaynaklı LLM modelleri de kolayca entegre edilebilmesi için yuvası yapılmıştır. Model seçimi yapıldıktan sonra "Browse Files" kısmından tarafınıza gönderilen csv formatındaki dosyayı yüklemelisiniz. Yüklenen dosya Şekil 2.'de gösterilmiştir.

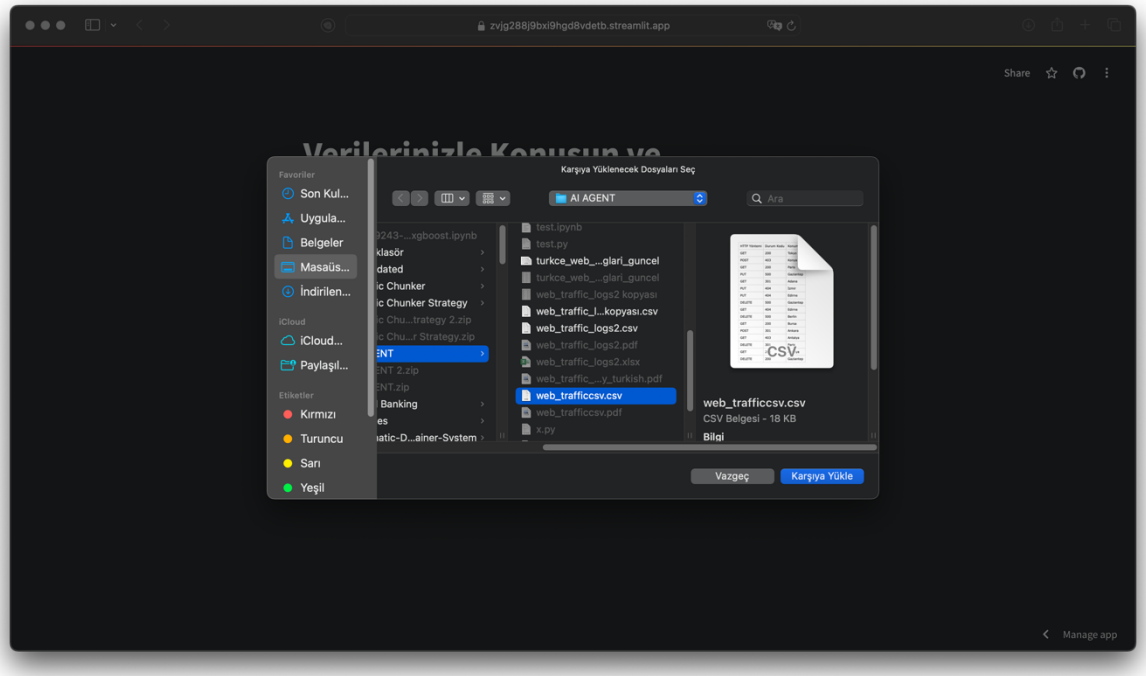

Şekil 2.

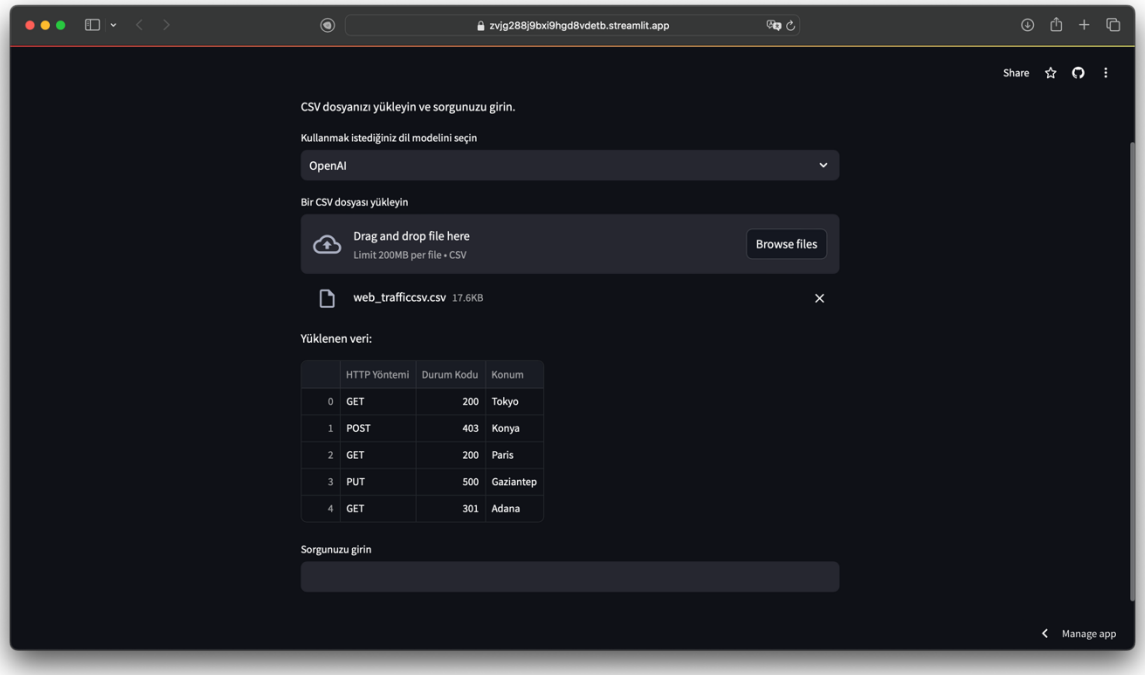

Şekil 3.

Veriyi başarıyla yükledikten sonra Şehil 3.'de de görüldüğü üzere kullanıcıdan sorgu alabilmek için bir sorgu balonu açılacaktır. Bu süreçten sonra açılan sorgu balonuna istediğiniz sorguyu girerek sonuçlarını inceleyebilirsiniz.

6. Performans ve Doğruluk Değerlendirmesi

6.1. Çıktı Kalitesinin ve Doğruluğun Değerlendirmesi

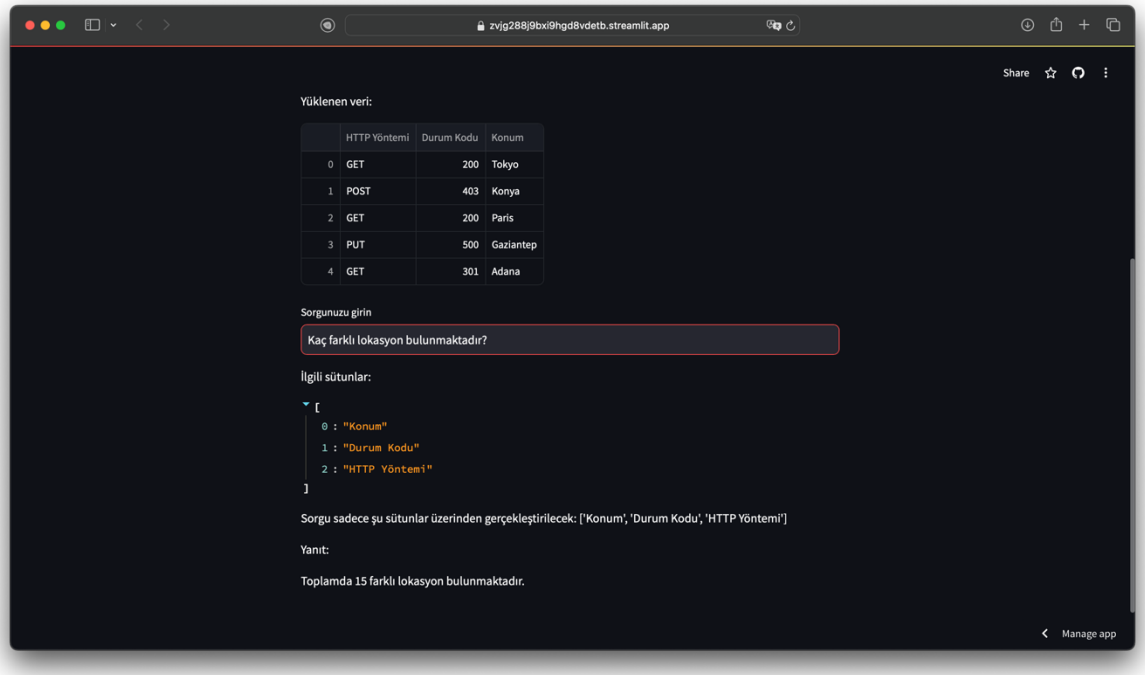

Şekil 4.

Şekil 4.'de görüldüğü üzere "Kaç farklı lokasyon bulunmaktadır?" sorgusuna modelin yanıtı "Toplamda 15 farklı lokasyon bulunmaktadır" olmuştur. Bu model yanıtı hem zengin hem de %100 doğruluğa sahiptir.

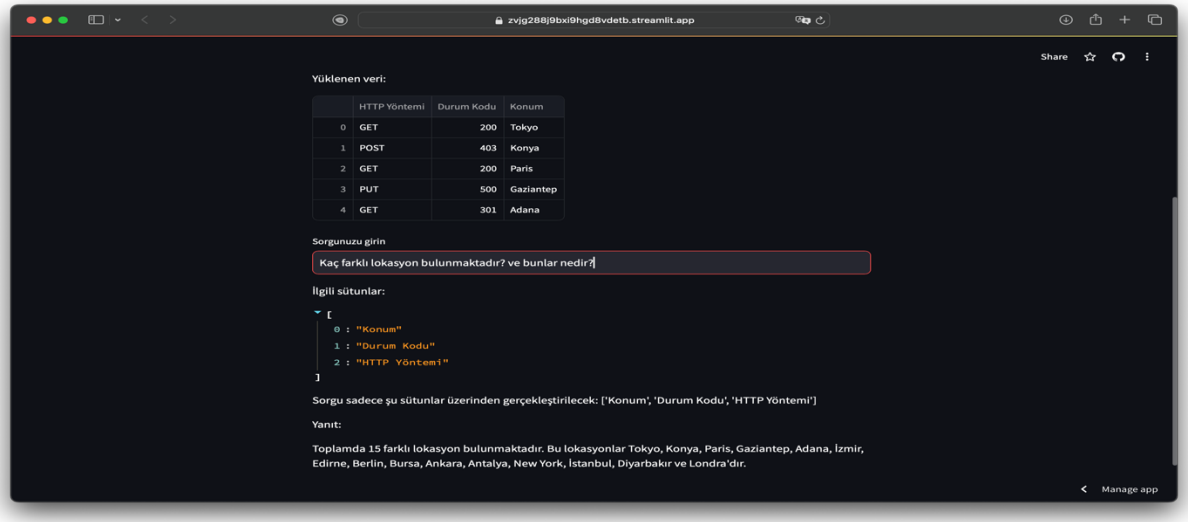

Şekil 5.

Şekil 5.'te bir önceki sorguyu daha detaylandırarak konum isimlerini sormuşuz ve model yine doğru bir cevap vermiştir.

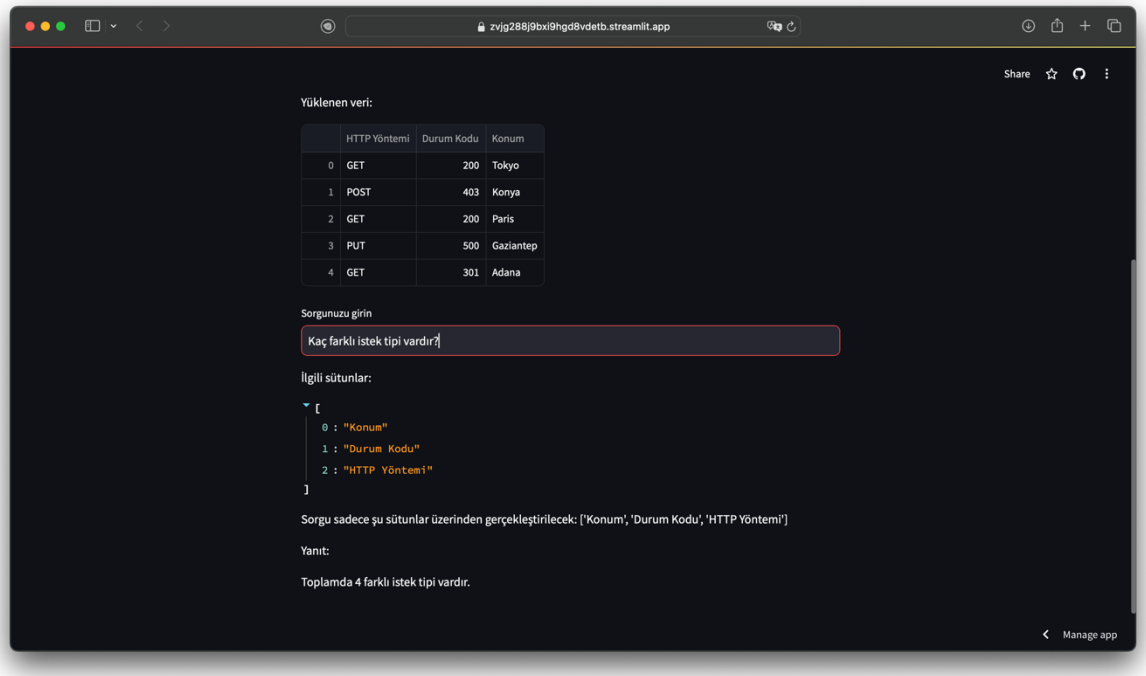

Şekil 6.

Şekil 6. incelendiğinde bu sefer veri setimizdeki HTTP Yöntemlerini kastederek "Kaç farklı istek tipi vardır?" diye bir soru sorduk ve sistem FAISS vektör veri tabanında kullanıcıdan gelen sorguya göre en yakın sütunları bulup sorguyu ilgili sütunlarda gerçekleştirip başarılı bir sonuç çıktısı üretti.

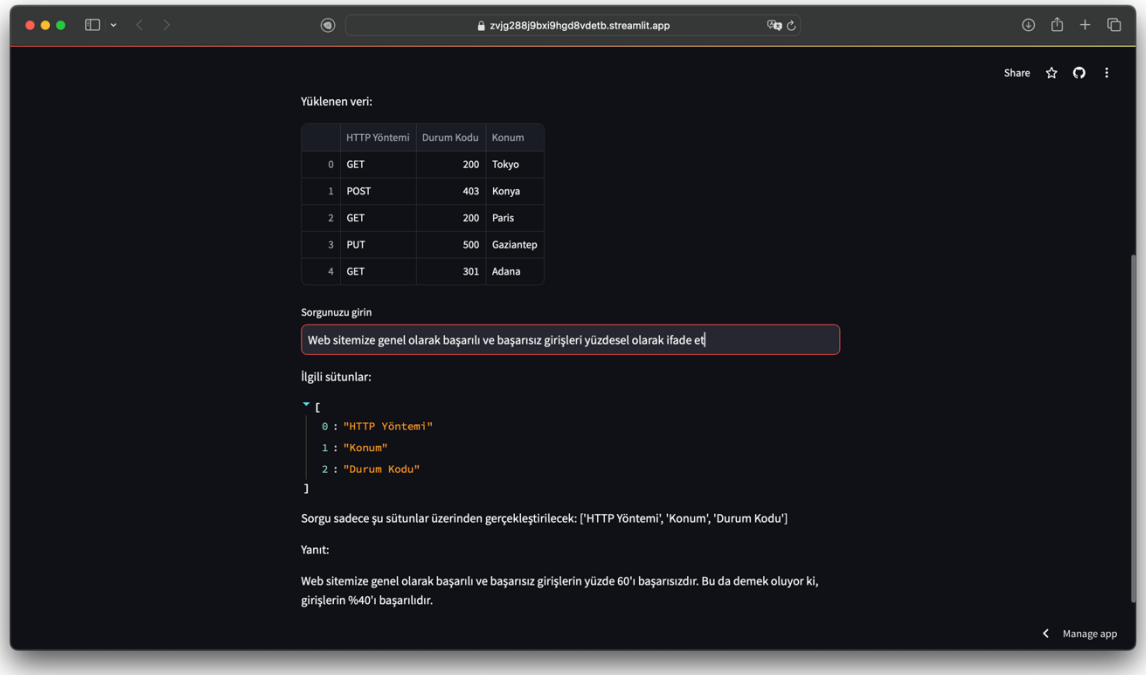

Şekil 7.

Şekil 7. incelendiğinde sorguyu biraz daha çeşitlendirerek web sitemizin loglarından oluşan veri setimize "Web sitemize genel olarak başarılı ve başarısız girişleri yüzdesel olarak ifade et" diye bir sorgu gönderdik ve genel olarak web sitemize girişlerin problemli mi yoksa problemsiz mi olduğunu sorgulamak istediğimizi düşünelim. Modelin çıktısı yine son derece doğru.

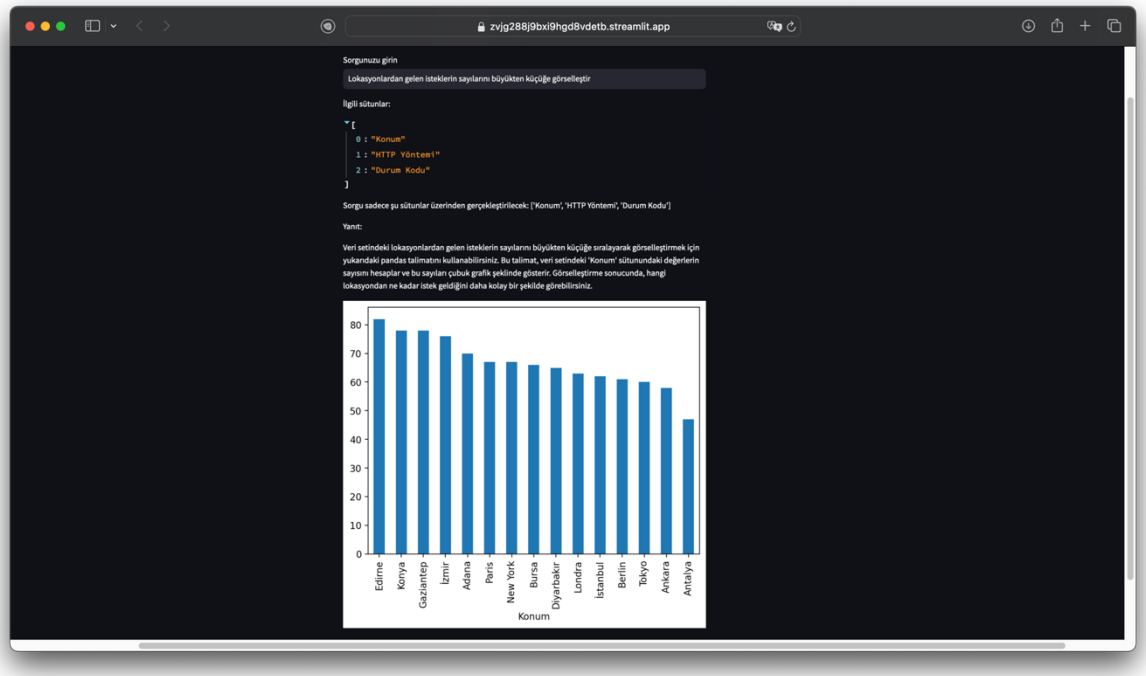

Şekil 8.

Normal şartlarda tarafımıza gönderilen görevde kullanıcıdan girdiye göre verileri görselleştirme gibi bir görev yoktu fakat bu projeyi yaparken projenin çok daha farklı boyutlara gelebileceğini fark edip geliştirmelere devam ettim. Şekil 8. incelendiğinde "Lokasyonlardan gelen isteklerin sayılarını büyükten küçüğe görselleştir" sorgusu girilmiş ve model başarıyla bir görselleştirme yaparak çıktı grafiğini üretmiştir. Bu sayede yüklenilen veri setinden istediğimiz görselleştirmeyi de yapabilir bir standarda erişmiş bulunduk.

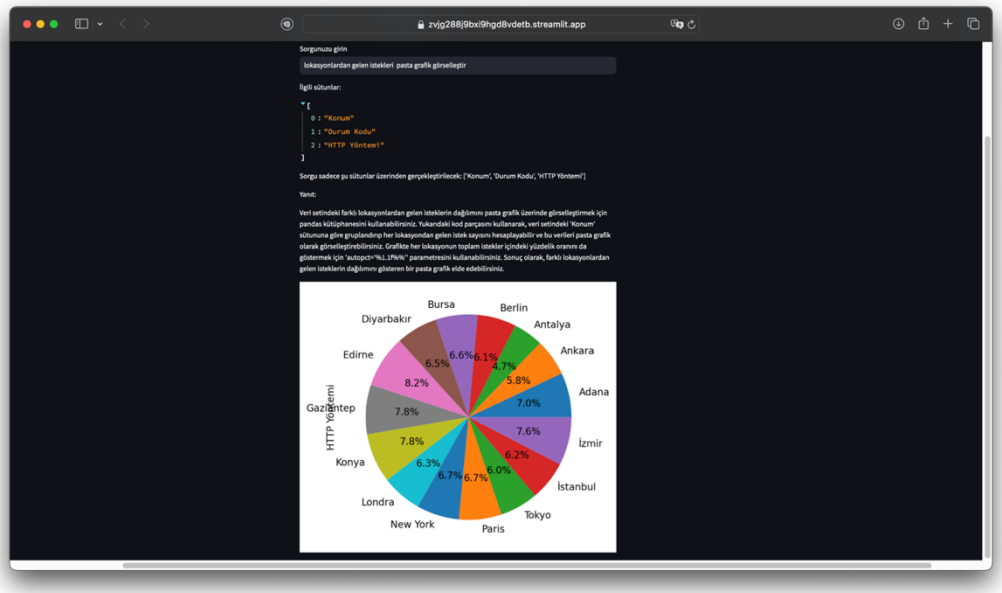

Şekil 9.

Şekil 9. incelendiğinde farklı görselleştirme teknikleri ile de görselleştirebildiğimizi ve aynı zamanda model tarafından ilgili grafiğe bir açıklama da getirdiğini görebiliyoruz.

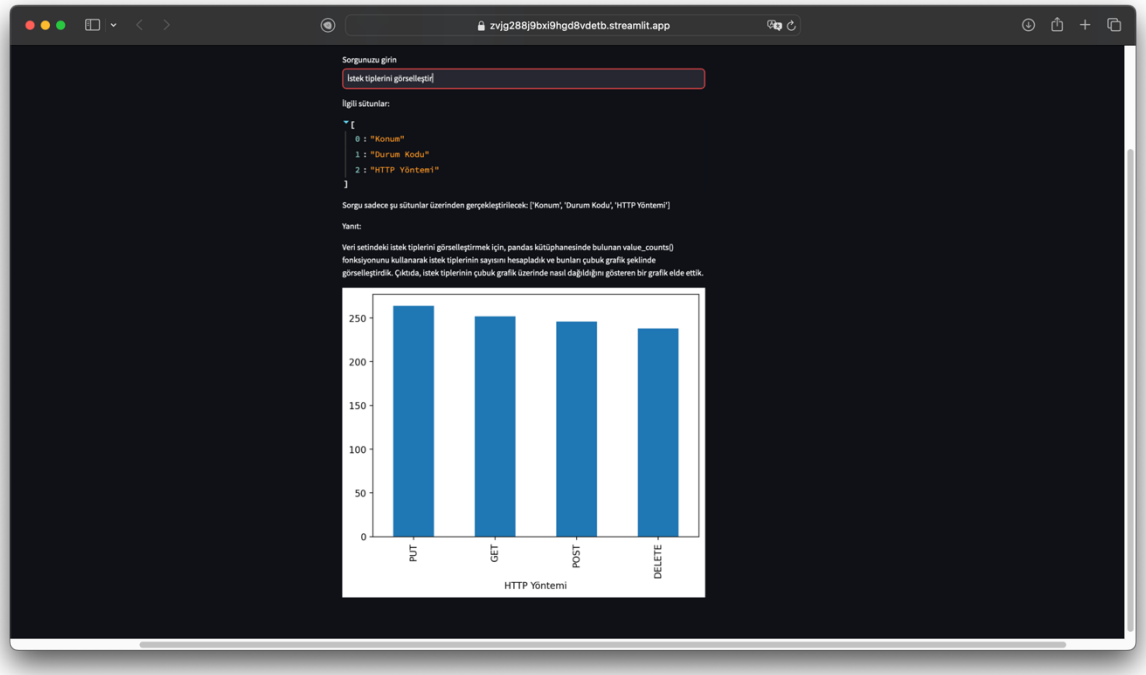

Şekil 10.

Şekil 10. incelendiğinde farklı sütunlar üzerinde de görselleştirme yapabileceğimizi görebiliyoruz.

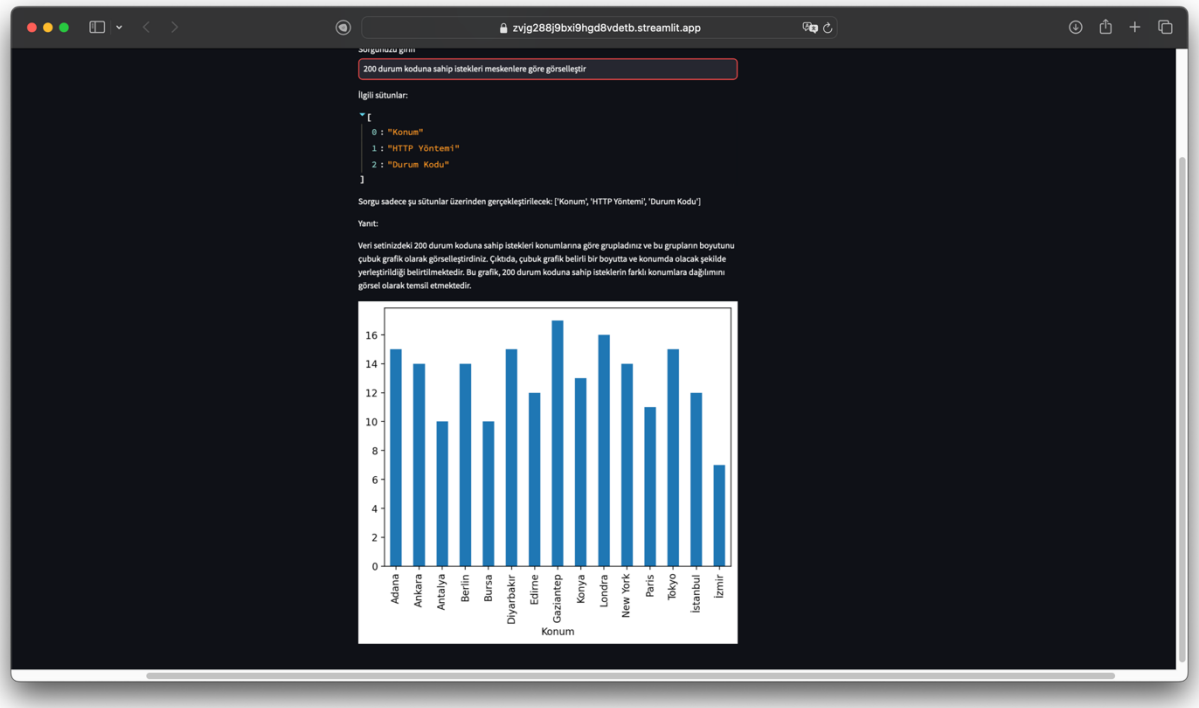

Şekil 11.

Şekil 11. incelendiğinde karmaşık sorgularda da yüksek performans ve kaliteli bir görselleştirme ürettiğini gözlemleyebiliyoruz.

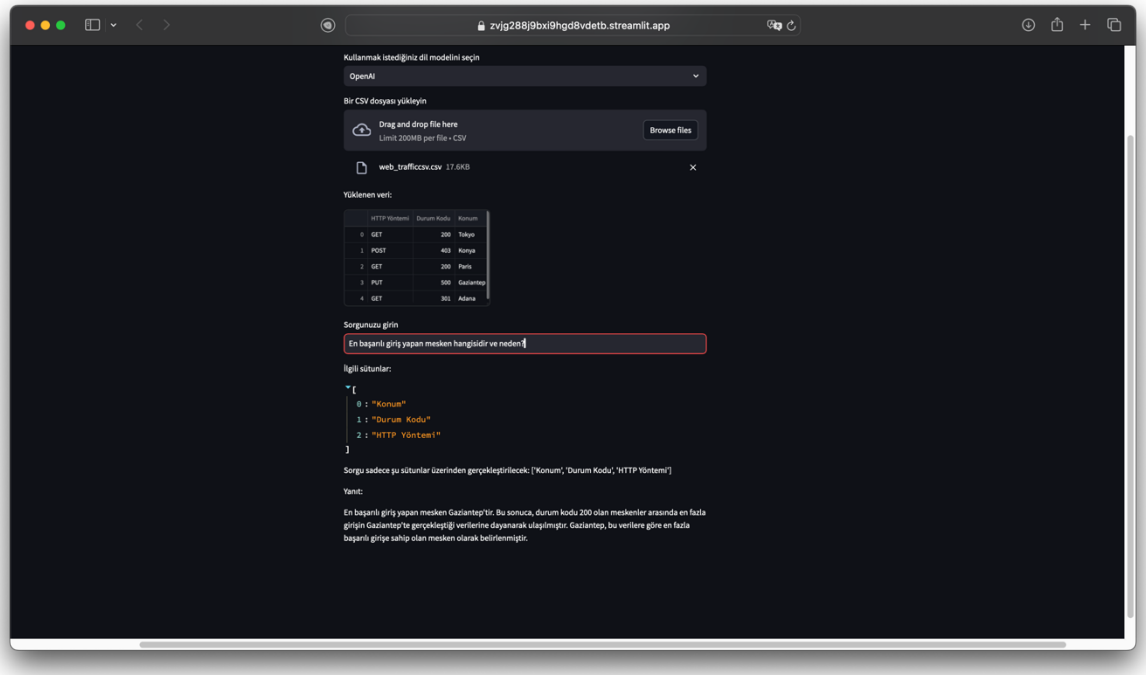

Şekil 12.

Şekil 12. incelendiğinde veri setine genel bir soru sorulmuş ve nedeni açıklattırılmış. Modelin çıktısı zengin, çeşitli ve son derece anlamlı.

Yapılan model tarafından yanıtların saniye bazında analizi incelendiğinde;

Saf Sorgular: 1-1,73 saniye

Grafik Sorgular: 1,25-2 saniye

Modelin çıktı hızları analiz edildiğinde hızlı, zengin, kaliteli ve doğru yanıtlar verdiği gözle görülmektedir.

7. Diğer Sorgular

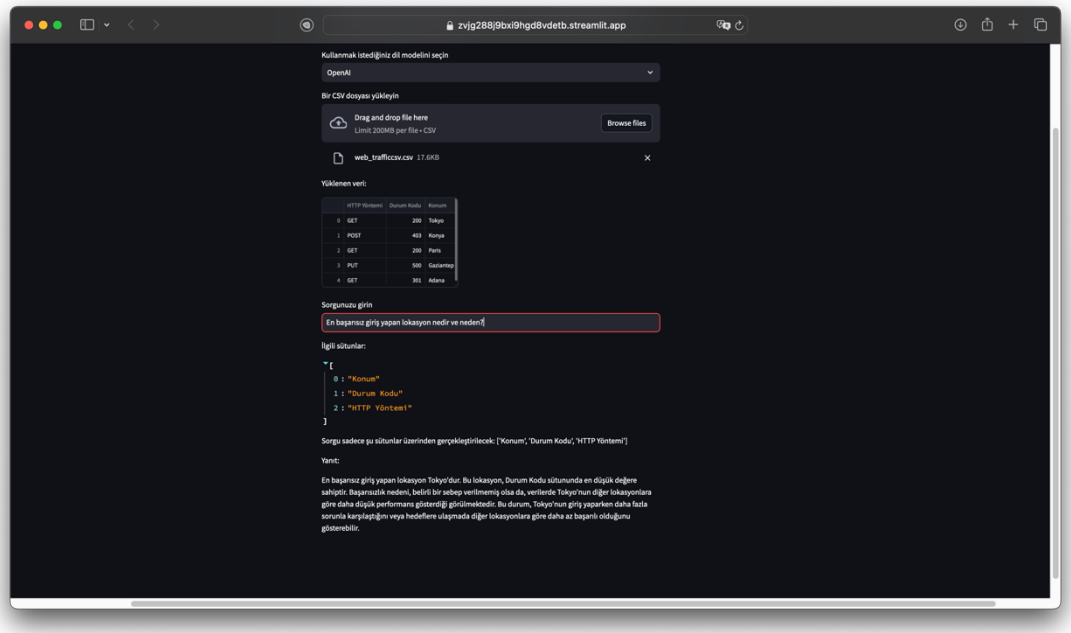

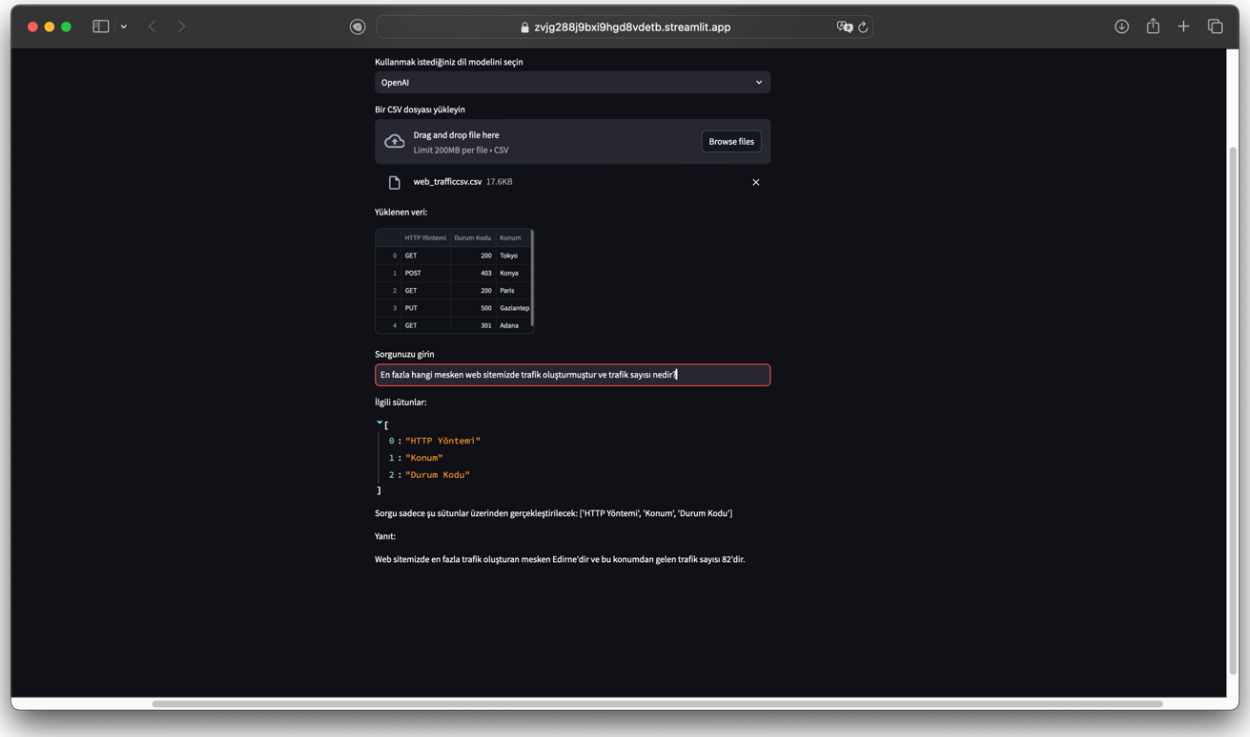

Şekil 14.

Şekil 14. incelendiğinde trafik sayısı gibi özel sorgulara kapsamlı bir anlamlandırma yaparak doğru ve kaliteli cevabı model üretmiş bulunmaktadır.

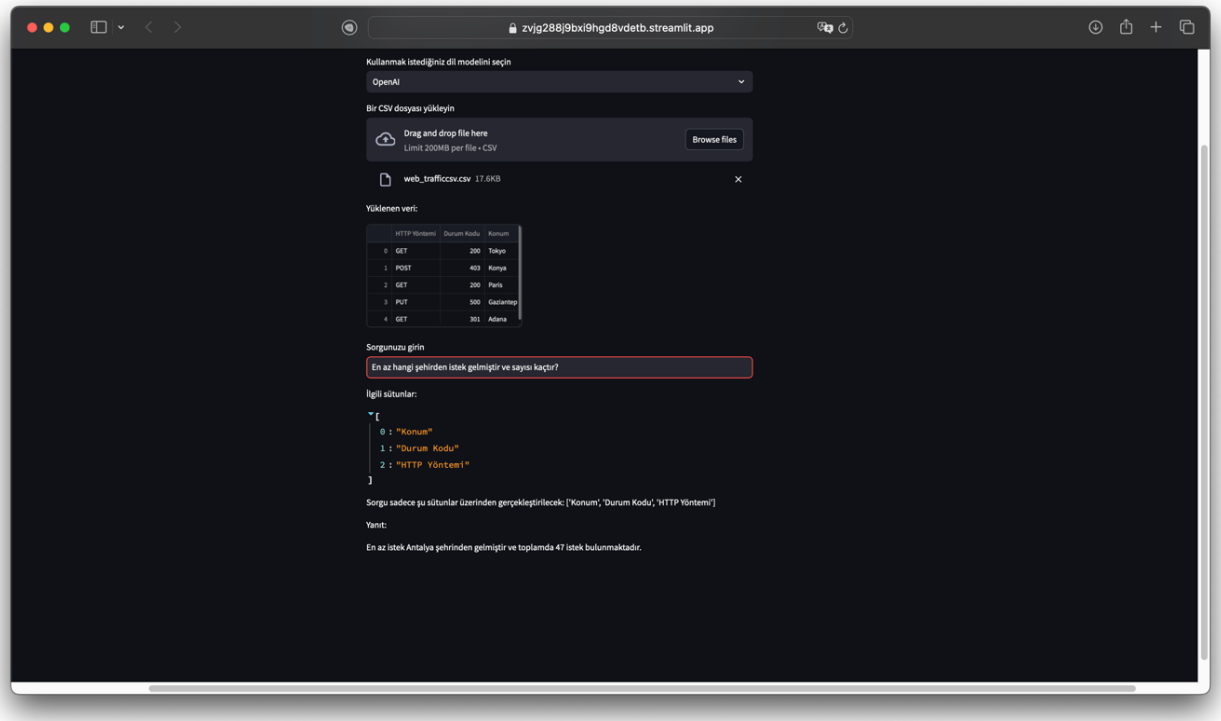

Şekil 15.

Şekil 15. incelendiğinde Konumlar bazında gelen istek sayılarının “en az” olanını sorgulayıp doğru ve kaliteli bir cevap almış bulunmaktayız.

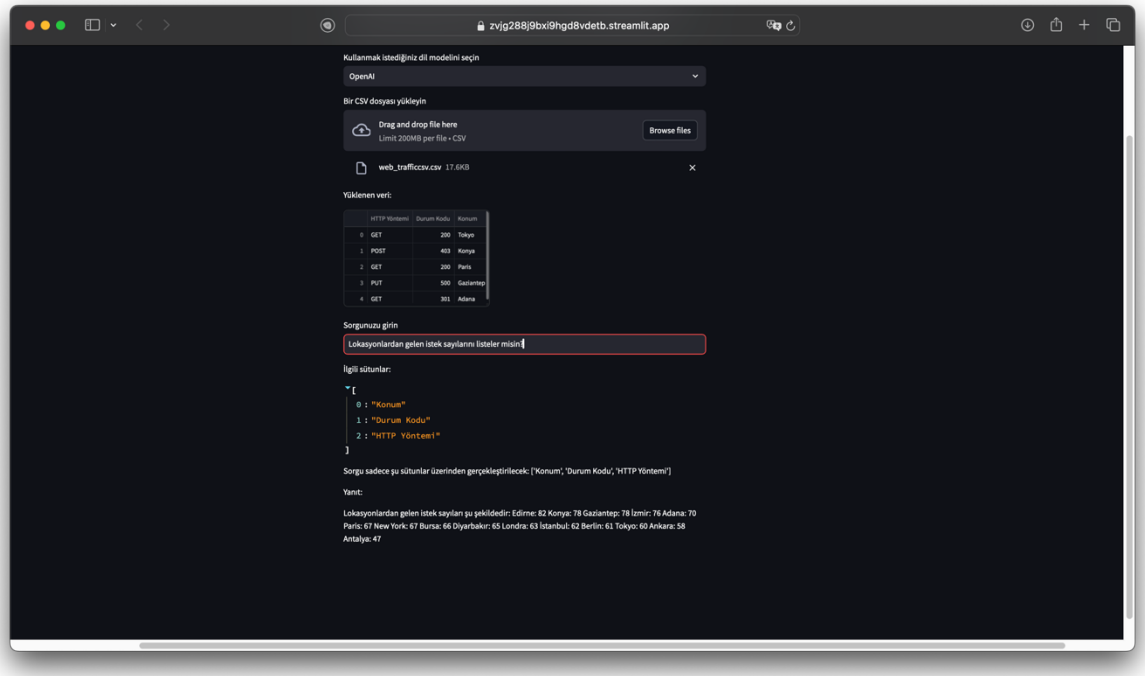

Şekil 16.

Son olarak “Lokasyonlardan gelen istek sayılarını listeler misin?” sorgusu ile lokasyon bazında gelen toplam istekleri gruplayıp modelimiz kaliteli ve doğru şekilde bir çıktı üretmiştir.

8. Sonuç ve Gelecek Çalışmalar

Bu proje, yapılandırılmış veriler üzerinde semantik arama yapmanın zorluklarını ele almış ve bu zorlukların üstesinden nasıl gelinebileceğini göstermiştir. Özellikle vektör veritabanlarının yapılandırılmış verilerde verimliliğinin düşük olmasının nedenlerini anlamak, bu projede izlenen çözüm yollarının geliştirilmesine yol açmıştır. Kullanıcı girdisine göre sütunların seçilmesi ve yalnızca bu sütunlar üzerinde sorgulama yapılması, sistemin daha tutarlı sorgular üretmesini sağlamış ve sonuçların daha güvenilir olmasına katkıda bulunmuştur. Performans analizleri incelendiğinde, modelin hem yüksek doğruluk hem de yüksek performans sunduğu görülmektedir. Ayrıca, sütun bazında yapılan sorgu tabanlı bir yaklaşım, hata oranlarını önemli ölçüde azaltmıştır. Bunun başlıca nedeni, sorgunun sadece belirli sütunlarla sınırlı kalmasıdır. Sorgunun çıktısı bir kod bloğu olarak döndüğü için, herhangi bir hata durumunda sistem, bu durumu yanıt içerisinde açıkça belirtmektedir.

Gelecek çalışmalarda, yapılandırılmış veri setleri üzerinde daha karmaşık sorgulamalar gerçekleştirmek amacıyla daha gelişmiş modelleme tekniklerinin kullanılması hedeflenebilir. Bunun yanı sıra, farklı türdeki veri setleri üzerinde bu yaklaşımın uygulanabilirliği araştırılabilir. Türkçe kelimelerle açık kaynaklı bir embedding modelinin fine-tune edilmesi, vektör veri tabanında yapılan sorguların kalitesini artırabilir ve Türkçe'ye özgü yüksek kaliteli bir embedding modeli geliştirilebilir. Kullanıcıdan alınacak geri bildirimler, modelin performansını değerlendirmede ve güncellemelerinde önemli bir rol oynayabilir.